

MEMORIA TÉCNICA DEL PROYECTO

Pipeline de Ingesta Climatológica y Energética

Arquitectura Medallion Bronze · Silver · Gold sobre Hadoop HDFS

Metodología aplicada	CRISP-DM (Cross-Industry Standard Process for Data Mining)
Módulo	Especialización en Inteligencia Artificial y Big Data
Asignatura	Sistemas de Big Data
Alumno	Hugo Blanco Alonso
Curso académico	2024 – 2025
Fases desarrolladas	I Comprensión del negocio · II Comprensión de los datos · III Preparación de los datos · VI Despliegue
Nota sobre fases IV/V	Modelado y Evaluación se omiten por estar fuera del ámbito del módulo de Big Data

El presente documento describe el ciclo de vida completo de un proyecto de Big Data orientado al análisis de la relación entre las condiciones meteorológicas y la generación de energía renovable en España. Se sigue rigurosamente la metodología **CRISP-DM**, articulando cada fase —desde la comprensión del negocio hasta el despliegue— sobre una infraestructura **Hadoop HDFS** con arquitectura Medallion (Bronze, Silver, Gold) y servicios cloud de **AWS S3** y funciones Lambda. Las fuentes de datos empleadas son la API de **AEMET**, la API de balance eléctrico de **REE/ESIOS** y un calendario de festivos nacionales 2024–2026. El resultado final es un dataset consolidado y un dashboard interactivo HTML que permite explorar la generación eólica e hidráulica en función de variables climáticas y del tipo de día.

FASE I Comprensión del Negocio

Business Understanding – Traducción del problema empresarial en objetivos de minería de datos

La primera fase de CRISP-DM exige comprender el contexto organizativo y definir con precisión qué valor aportará el proyecto. La transición energética española hacia fuentes renovables genera una necesidad analítica clara: **entender cómo las condiciones climáticas determinan la capacidad de generación eólica e hidráulica** y cómo el comportamiento del consumo varía según el calendario laboral.

1.1 Contexto y Problema de Negocio

La Red Eléctrica de España (REE/ESIOS) publica diariamente los datos de balance eléctrico por tecnología. Sin embargo, la correlación entre los datos meteorológicos (temperatura, velocidad del viento, precipitación) y los niveles de generación renovable no está sistematizada en una sola fuente de verdad accesible para análisis. Este proyecto construye esa fuente única mediante un pipeline ETL robusto sobre un entorno Big Data.

■ **Objetivo de negocio:** Construir una plataforma de datos integrada que permita analizar la correlación entre variables meteorológicas (AEMET) y la generación de energía renovable (REE/ESIOS), incorporando el efecto del calendario festivo, para apoyar decisiones de planificación energética.

1.2 Valor del Proyecto y ROI Esperado

El valor del proyecto se articula en tres dimensiones complementarias:

- **Operativo:** Reducción del tiempo de análisis manual de datos dispersos en múltiples APIs y formatos heterogéneos.
- **Analítico:** Base de datos unificada y versionada (Parquet) que permite construir modelos predictivos de generación renovable.
- **Estratégico:** Apoyo a la toma de decisiones en gestión de la demanda y planificación de reservas energéticas en función del clima y la estacionalidad.

1.3 Fuentes de Datos Identificadas

Fuente de Datos	Descripción y Alcance
AEMET (API REST)	Datos climáticos diarios: temperatura máxima, mínima y media (°C), racha máxima de viento (km/h), velocidad del viento y precipitación por franjas horarias (00–06h, 06–12h, 12–18h, 18–24h). Cobertura: últimos 5 meses a nivel de estación meteorológica y provincia.

REE / ESIOS (API v2)	Balance eléctrico histórico: generación eólica e hidráulica en MWh con porcentaje sobre el total del sistema. Estructura JSON anidada compleja con acceso mediante clave de API. Frecuencia: diaria. Actualización automática mediante AWS Lambda.
Calendario Festivos	CSV con la clasificación de todos los días del periodo 2024–2026 en tres categorías: Laboral, Fin de semana y Festivo (nacional). Generado estáticamente a partir del BOE.
AWS S3	Bucket de almacenamiento intermedio (capa Bronze) donde las funciones Lambda depositan los JSON diarios de ESIOS antes de su procesamiento hacia la capa Silver en HDFS.

1.4 Variable Objetivo y Tipo de Análisis

El proyecto no plantea un modelo supervisado único, sino un **análisis exploratorio y descriptivo** orientado a la comprensión de relaciones. Las variables principales de interés son:

- **valor (MWh):** generación eléctrica absoluta diaria por tipo de energía renovable.
- **porcentaje (%):** peso relativo de cada fuente en el mix eléctrico nacional.
- **Variables climáticas agregadas:** HDD, CDD, amplitud térmica y precipitación total calculada.

1.5 Tabla Resumen CRISP-DM Fase I

Bloque CRISP-DM	Tipo / Técnica	Detalle del Proyecto
Objetivo de negocio	Analítico / Exploratorio	Correlacionar clima y generación renovable para apoyar planificación energética
Valor del proyecto	Operativo + Estratégico	Unificación de fuentes heterogéneas; base para modelos predictivos futuros
Fuentes de datos	API REST + CSV + S3	AEMET, REE/ESIOS, BOE Festivos, AWS Lambda + S3
Variable objetivo	Númerica continua	Valor MWh y porcentaje de generación eólica e hidráulica
Calidad y riesgos	Nulos, outliers, sesgo temporal	Missings en columnas de viento; datos inconsistentes en horas de registro
Preparación clave	ETL Medallion	IQR clipping, log1p en viento, HDD/CDD, One-Hot Encoding, merge por fecha
KPI de evaluación	Cobertura y completitud	% de registros válidos tras limpieza; rango temporal cubierto
Despliegue previsto	Dashboard HTML + HDFS	Archivo Parquet en capa Gold + dashboard interactivo exportable

FASE II Comprensión de los Datos

Data Understanding – EDA, calidad, estructura y descripción de las fuentes

En esta fase se realiza el primer contacto técnico profundo con las tres fuentes de datos. El objetivo es caracterizar cada dataset, identificar problemas de calidad y extraer conocimiento inicial sobre distribuciones y relaciones entre variables.

2.1 Recolección Inicial y Volumen de Datos

≈125.000 Registros AEMET (brutos)	≈258 Registros ESIOS (días × 2 energías)	1.096 Días en calendario festivos	≈103.000 Registros en dataset consolidado Gold
---	--	---	--

Los datos de AEMET presentan una granularidad de **estación meteorológica × día**, con más de 700 estaciones distribuidas por toda la geografía española. Los datos de ESIOS tienen granularidad **diaria nacional**, con dos registros por día (uno por tipo de energía: Eólica e Hidráulica). El calendario de festivos cubre 1.096 días del periodo 2024–2026.

2.2 Descripción Estructural de los Datasets

2.2.1 Dataset AEMET (datos_aemet.csv)

Variable	Descripción y Observaciones
Estación	Nombre de la estación meteorológica (texto libre)
Provincia	Provincia española donde se ubica la estación
Temperatura máxima (°C)	Valor numérico + hora de registro en formato '14.7 (16:30)' — requiere parsing
Temperatura mínima (°C)	Mismo formato compuesto que la temperatura máxima
Temperatura media (°C)	Valor numérico directo como string; algunos registros con coma decimal
Racha (km/h)	Velocidad máxima de racha en formato compuesto — 22.328 nulos (~18%)
Velocidad máxima (km/h)	Velocidad media máxima — 21.877 nulos (~17%)
Precipitación 00-24h	Acumulado diario total en mm — 8.391 nulos (~7%)
Precipitación 00-06h	Franja nocturna — 7.186 nulos

Precipitación 06-12h	Franja mañana — 7.554 nulos
Precipitación 12-18h	Franja tarde — 7.346 nulos
Precipitación 18-24h	Franja noche — 7.068 nulos
fecha	Fecha del registro en formato YYYY-MM-DD — sin nulos

2.2.2 Dataset ESIOS (balance_electrico_historico.json)

El JSON de ESIOS tiene una estructura anidada compleja: data → included → attributes → content → attributes → values. El parsing iterativo extrae los valores de generación para las tecnologías 'Eólica' e 'Hidráulica'.

Variable	Descripción
tipo de energia	Categoría de generación: 'Eólica' o 'Hidráulica'
valor	Generación en MWh del día (float)
porcentaje	Participación porcentual en el mix eléctrico (float, formato decimal 0-1 en origen)
fecha	Timestamp ISO 8601 con zona horaria '+01:00' — requiere normalización a YYYY-MM-DD

2.2.3 Dataset Festivos (calendario_festivos_2024_2026.csv)

Variable	Descripción
fecha	Fecha en formato YYYY-MM-DD — sin nulos, cobertura completa 2024–2026
tipo_dia	Clasificación: 'Laboral' (763 días), 'Fin de semana' (307 días), 'Festivo' (26 días)

2.3 Análisis Exploratorio de Datos (EDA)

2.3.1 Análisis Univariante – Temperatura Máxima

El análisis del boxplot inicial de temperatura máxima reveló la presencia de outliers significativos en las colas de la distribución, consecuencia de errores de registro en algunas estaciones remotas. La distribución presenta un rango original muy amplio, con valores que se alejan considerablemente de los percentiles Q1 y Q3.

■ **Hallazgo EDA:** La columna 'Temperatura máxima (°C)' contenía valores registrados en formato compuesto ('14.7 (16:30)'), mezclando el valor numérico con la hora del registro. Fue necesario un parsing vectorizado con `str.split(' ').str[0]` para extraer únicamente el valor numérico antes de cualquier análisis estadístico.

2.3.2 Análisis Univariante – Variables de Viento

Las variables de racha y velocidad máxima de viento presentaron una distribución fuertemente sesgada a la derecha (asimetría positiva), con la mayoría de los valores concentrados en rangos bajos y una cola larga hacia valores altos. Este comportamiento es típico de datos de intensidad del viento.

■ **Hallazgo EDA:** La distribución logarítmica del viento (log10) mostró un patrón mucho más próximo a la normalidad, confirmando la conveniencia de aplicar una transformación logarítmica en la fase de preparación. Los outliers residuales se controlaron adicionalmente con clipping IQR.

2.3.3 Análisis de Valores Ausentes

Variable	Nulos absolutos	Porcentaje
Temperatura máxima/mínima/media	~6.011 por columna	~4,8 % del total bruto
Racha (km/h)	22.328	~17,9 %
Velocidad máxima (km/h)	21.877	~17,5 %
Precipitación 00-24h	8.391	~6,7 %
Precipitación franjas horarias	7.068 – 7.554	~5,7 – 6,0 %
fecha	0	Sin nulos
ESIOS: todos los campos	0	Sin nulos
Festivos: todos los campos	0	Sin nulos

FASE III Preparación de los Datos

Data Preparation – Limpieza, transformación, feature engineering e integración

Esta es la fase de mayor carga técnica del proyecto. Se articuló en dos etapas correspondientes a la arquitectura Medallion: **Bronze** → **Silver** (limpieza y transformación) y **Silver** → **Gold** (integración, enriquecimiento y formateo final).

3.1 Arquitectura Medallion del Pipeline ETL

CAPA	TECNOLOGÍA	DESCRIPCIÓN
■ BRONZE	AWS S3 + Lambda	Datos crudos sin transformar. Lambda 1 extrae el JSON diario de ESIOs y lo deposita en S3. Lambda 2 acumula el histórico. AEMET y festivos se descargan manualmente.
■ SILVER	Jupyter + Pandas + HDFS	Datos limpios y transformados. Se aplica IQR clipping, log1p en viento, parsing de formatos mixtos y normalización de fechas. Exportación a Parquet en /datalake/plata/.
■ GOLD	Jupyter + Pandas + HDFS	Dataset analítico consolidado. Inner join de las tres fuentes, feature engineering (HDD, CDD, amplitud térmica), codificación categórica y exportación final a /datalake/oro/datos/.

3.2 Selección y Limpieza de Datos – Capa Silver (AEMET)

3.2.1 Tratamiento de Valores Ausentes

Tras el análisis de nulos de la fase anterior, se decidió aplicar la política de **eliminación de filas** mediante `df.dropna()`. La justificación es cuantitativa: el dataset AEMET cuenta con aproximadamente 125.000 registros, y las columnas más críticas (temperatura, viento) presentan sólo un 4,8–17,9% de nulos. La eliminación no compromete la representatividad del conjunto resultante.

■ **Decisión justificada:** Con 125.000 registros totales, eliminar las ~6.000 filas con nulos en temperatura (4,8%) o las ~22.000 con nulos en viento (17,9%) sigue siendo viable estadísticamente. El resultado final mantiene cobertura geográfica y temporal suficiente para el análisis. Una imputación por media/mediana habría introducido varianza artificial en variables con distribución sesgada.

3.2.2 Parsing de Formatos Mixtos

Las columnas de temperatura y viento llegaron con formato compuesto 'valor (hh:mm)'. Se aplicó parsing vectorizado para extraer únicamente la parte numérica:

```
df[col] = df[col].astype(str).str.split(' ').str[0]
```

Posteriormente se convirtieron a tipo numérico con manejo de errores y relleno de ceros para valores no parseables:

```
pd.to_numeric(df[col].str.replace(',', '.'), errors='coerce').fillna(0)
```

3.2.3 Tratamiento de Outliers – IQR Clipping

Para las variables numéricas se aplicó la técnica de **clipping basado en el Rango Intercuartílico (IQR)**. A diferencia de la eliminación de filas, el clipping estabiliza los valores extremos sin perder registros, preservando la distribución general de los datos.

```
Q1 = df[col].quantile(0.25) Q3 = df[col].quantile(0.75) IQR = Q3 - Q1 df[col] =  
df[col].clip(lower=Q1 - 1.5*IQR, upper=Q3 + 1.5*IQR)
```

Se aplicó sobre: **Temperatura máxima, Temperatura mínima, Racha (km/h) y Velocidad máxima (km/h)**.

3.2.4 Transformación Logarítmica del Viento

Dada la distribución fuertemente sesgada a la derecha de las variables de viento, se aplicó la transformación **log₁₀(x + 1)** mediante `np.log10()` (previo relleno de ceros para evitar $\log(0) = -\infty$). Esta transformación comprime los valores extremos y aproxima la distribución a la normalidad, optimizando la variable para futuros modelos estadísticos.

■ **Nota técnica:** Se utilizó **log₁₀** en lugar de **log_{1p}** (log natural + 1) porque las variables de viento ya presentaban valores enteros ≥ 0 y la escala decimal facilita la interpretación (1 $\approx$ 10 km/h, 2 $\approx$ 100 km/h). Los ceros originales se rellenaron antes de la transformación con **fillna(0)**.

3.3 Limpieza de Datos – Capa Silver (ESIOS)

3.3.1 Parsing de Estructura JSON Anidada

La API de ESIOS devuelve una estructura JSON con cinco niveles de anidamiento. Se implementó un extractor iterativo que recorre `data['included']` y filtra únicamente las tecnologías 'Eólica' e 'Hidráulica', construyendo un DataFrame plano con cuatro columnas.

3.3.2 Normalización de Fechas y Porcentajes

Las fechas en ESIOS venían en formato ISO 8601 con zona horaria ('2026-01-11T00:00:00.000+01:00'). Se normalizaron a YYYY-MM-DD:

```
pd.to_datetime(df['fecha'], utc=True).dt.strftime('%Y-%m-%d')
```

Los porcentajes, que llegaban en formato decimal (0.174...), se multiplicaron por 100 y se redondearon a un decimal para mejorar la legibilidad y comparabilidad.

3.4 Integración de Datos – Construcción del Dataset Gold

3.4.1 Estrategia de Join

Los tres datasets se unificaron mediante un **inner join** sobre la clave común fecha (string YYYY-MM-DD). La elección del inner join garantiza que sólo se incluyan registros con información completa en las tres fuentes, evitando registros con valores nulos estructurales.

```
df = df_aemet.merge(df_esios, on='fecha', how='inner') .merge(df_festivos, on='fecha',
how='inner')
```

El resultado es un dataset con ~103.846 registros en granularidad **estación × tipo_energía × día**.

3.5 Ingeniería de Características (Feature Engineering)

3.5.1 Heating Degree Days (HDD) y Cooling Degree Days (CDD)

Se crearon los indicadores estándar del sector energético para cuantificar la **demanda de climatización estimada**. La temperatura base de referencia es 18 °C, umbral convencional de confort térmico:

```
HDD = max(0, 18 - T_media) # Demanda de calefacción CDD = max(0, T_media - 18) # Demanda de refrigeración
```

Implementación vectorizada: `(18 - pd.to_numeric(df['Temperatura media (°C)'])).clip(lower=0)`

3.5.2 Amplitud Térmica Diaria

Variable derivada que cuantifica la diferencia entre temperatura máxima y mínima en cada estación y día. Alta amplitud térmica está asociada a condiciones de mayor viento y menor nubosidad en muchas regiones peninsulares.

```
df['Amplitud_Termica'] = df['Temperatura máxima (°C)'] - df['Temperatura mínima (°C)']
```

3.5.3 Precipitación Total Calculada

Se construyó una variable de precipitación diaria total como suma robusta de los cuatro tramos de 6 horas, proporcionando una alternativa al campo '00-24h' que contenía un mayor porcentaje de nulos:

```
df['Precipitacion_Total_Calculada'] = ( df['Precipitación 00-06h (mm)'] + df['Precipitación 06-12h (mm)'] + df['Precipitación 12-18h (mm)'] + df['Precipitación 18-24h (mm)'] )
```

3.6 Formateo y Codificación de Variables Categóricas

3.6.1 Ordinal Encoding del Calendario Laboral

La variable `tipo_dia` se codificó mediante **mapeo ordinal determinista** preservando la semántica del orden natural de actividad laboral:

```
mapa = {'Fin de semana': 0, 'Laborable': 1, 'Festivo': 2} df['tipo_dia_encoded'] = df['tipo_dia'].map(mapa)
```

■ **Decisión de diseño:** Se eligió ordinal encoding (no one-hot) para `tipo_dia` porque existe un orden conceptual real de actividad económica: fin de semana (consumo mínimo) < festivo (consumo reducido) < laborable (consumo máximo). Esto permite que futuros modelos de regresión capturen esta relación de forma natural.

3.6.2 One-Hot Encoding del Tipo de Energía

La variable binaria `tipo de energia` (Eólica / Hidráulica) se codificó mediante One-Hot Encoding con eliminación de la primera categoría para evitar multicolinealidad. El resultado es la columna `tipo de energia_Hidráulica` (1 = Hidráulica, 0 = Eólica):

```
pd.get_dummies(df, columns=['tipo de energia'], drop_first=True, dtype=int)
```

3.7 Resultado Final de la Capa Gold

22	~103.8K	Parquet	HDFS
Variables en el dataset Gold	Registros consolidados	Formato de persistencia	Almacenamiento final
Variable	Tipo / Transformación	Descripción	
Estación / Provincia	Texto (string)	Identificador geográfico de la observación climática	
Temperatura máxima/mínima (°C)	Float – clipeada	Post IQR clipping; outliers estabilizados	
Temperatura media (°C)	Float	Usada para calcular HDD y CDD	
Racha / Velocidad (km/h)	Float – log10	Transformación logarítmica + IQR clipping	
Precipitación franjas (mm)	Float	4 franjas horarias + columna calculada total	
valor (MWh)	Float	Generación eléctrica diaria absoluta	
porcentaje (%)	Float	Participación en el mix eléctrico × 100	
tipo_dia	String categórico	Laboral / Fin de semana / Festivo	
tipo_dia_encoded	Integer (0/1/2)	Ordinal encoding del calendario laboral	
tipo de energía_Hidráulica	Integer (0/1)	OHE: 1=Hidráulica, 0=Eólica	
HDD	Float ≥ 0	Grados día de calefacción (base 18 °C)	
CDD	Float ≥ 0	Grados día de refrigeración (base 18 °C)	
Amplitud_Termica	Float	Diferencia T_max – T_min por estación y día	
Precipitacion_Total_Calculada	Float ≥ 0	Suma de las 4 franjas horarias de precipitación	

FASES IV y V Modelado y Evaluación

Fuera del ámbito del módulo de Sistemas de Big Data

■ ■ **Nota académica:** Conforme a las instrucciones del módulo de Sistemas de Big Data de la Especialización en Inteligencia Artificial y Big Data, las fases IV (Modelado) y V (Evaluación) de la metodología CRISP-DM quedan fuera del alcance de este proyecto. Ambas fases forman parte del itinerario de las asignaturas de Aprendizaje Automático e Inteligencia Artificial.

No obstante, el dataset consolidado resultante de la Fase III (capa Gold) está completamente preparado para ser consumido por algoritmos de Machine Learning en un proyecto posterior. Las transformaciones aplicadas — escalado de variables, codificación categórica, creación de features como HDD y CDD — responden precisamente a los requisitos de preparación de datos que exigen los algoritmos supervisados de regresión y clasificación.

Modelos candidatos para una fase de modelado futura:

Algoritmo	Tipo	Aplicación potencial
Regresión lineal múltiple	Supervisado – Regresión	Predecir el valor (MWh) de generación eólica en función de temperatura, viento y HDD
Random Forest Regressor	Supervisado – Regresión	Capturar relaciones no lineales entre clima y generación energética
Gradient Boosting (XGBoost)	Supervisado – Regresión	Optimizar predicción de porcentaje de participación en el mix eléctrico
K-Means Clustering	No supervisado	Identificar perfiles de días con patrones similares de clima y generación
Serie temporal (ARIMA/LSTM)	Temporal	Predecir la generación futura basada en patrones históricos estacionales

FASE VI Despliegue

Deployment – Persistencia en HDFS, automatización AWS y dashboard interactivo

La fase de despliegue materializa el valor del proyecto haciéndolo accesible y sostenible en el tiempo. Se estructuró en tres componentes independientes: la automatización de la ingesta en AWS, la persistencia en HDFS y el dashboard interactivo para el usuario final.

6.1 Automatización de la Ingesta – AWS Lambda + S3

Se implementaron dos funciones AWS Lambda que automatizan la actualización diaria del histórico de datos de generación eléctrica de REE/ESIOS:

Lambda 1: Ingesta Diaria (trigger EventBridge)

Se ejecuta automáticamente cada día a una hora programada mediante un desencadenador Amazon EventBridge. Realiza una petición GET a la API de ESIOs con el rango `start_date=hoy&end_date=hoy&time_trunc=day` y deposita el JSON resultante en el bucket S3 `bronze-hugoblancoalonso/bronze/esios/diario/` con nombre `balance_electrico_YYYYMMDD.json`.

Lambda 2: Acumulación Histórica (trigger S3 PUT)

Se dispara automáticamente cada vez que la Lambda 1 deposita un nuevo archivo en S3. Lee el archivo diario más reciente, lo fusiona con el JSON histórico acumulado (`bronze/esios/historico/balance_electrico_historico.json`) y sobrescribe el histórico con los nuevos registros añadidos.

■ ■ **Arquitectura serverless:** El enfoque Lambda + S3 elimina la necesidad de mantener un servidor siempre activo para la ingesta. El coste operativo es mínimo (sólo se paga por invocación) y la arquitectura escala automáticamente. El bucket S3 actúa como capa Bronze del datalake en la nube, desacoplada del procesamiento local en Hadoop.

6.2 Persistencia en Hadoop HDFS – Arquitectura Medallion

Los tres niveles de transformación se persisten en rutas diferenciadas dentro del cluster Hadoop local, garantizando trazabilidad completa del linaje de datos:

Ruta HDFS	Contenido
<code>/datalake/plata/clima/</code>	<code>datos_aemet.parquet</code> — datos AEMET limpios y transformados
<code>/datalake/plata/consumo/</code>	<code>datos_esios.parquet</code> — datos ESIOs con fechas normalizadas y porcentajes escalados

/datalake/plata/festivos/	datos_festivos.parquet — calendario de festivos 2024–2026
/datalake/oro/datos/	datos_consolidados.parquet — dataset Gold integrado con todas las features

La conexión a HDFS se realiza mediante la librería `hdfs` (WebHDFS) con el cliente `InsecureClient` apuntando al NameNode en `http://namenode:9870`. El flujo de carga incluye borrado del archivo previo si existe, creación recursiva del directorio y subida del nuevo Parquet.

```
client = InsecureClient('http://namenode:9870', user='root') if client.status(ruta_hdfs, strict=False): client.delete(ruta_hdfs) client.makedirs(os.path.dirname(ruta_hdfs)) client.upload(ruta_hdfs, archivo_local)
```

■ **Formato Parquet:** Se eligió Apache Parquet como formato de almacenamiento por su alta eficiencia en compresión columnar (reducción de ~60–70% respecto a CSV), soporte nativo de tipos de datos, compatibilidad con Spark/Hive y lectura predicate pushdown que acelera las consultas analíticas sobre subconjuntos de columnas.

6.3 Dashboard Interactivo HTML

El entregable final para el usuario es un **dashboard HTML autocontenido** generado mediante Python (módulo `dashboard_df_consolidado.py`) que embebe el dataset Gold serializado como JSON en el propio HTML. Toda la lógica de filtrado y renderizado se ejecuta en el navegador cliente mediante JavaScript puro y la librería **Plotly.js**, sin necesidad de servidor backend.

6.3.1 Capacidades de Filtrado Interactivo

- Filtro por **Provincia** y **Estación meteorológica** (cascada dinámica).
- Filtro por **rango de fechas** (inicio y fin).
- Filtro por **tipo de día** (Laboral, Fin de semana, Festivo) con selección múltiple.
- Filtro por **fuelle de energía** (Ambas / Solo Eólica / Solo Hidráulica).
- Control de **Top N** categorías en gráficos de barras (rango 5–25).

6.3.2 Visualizaciones Disponibles

Visualización	Tipo	Descripción
Serie temporal	Gráfico de líneas	Evolución diaria de cualquier variable numérica (valor, temperatura, HDD, precipitación) sobre el subconjunto filtrado
Comparativa por grupo	Gráfico de barras	Top N provincias o estaciones por valor medio de generación
Mix energético	Gráfico de tarta	Distribución porcentual media de generación eólica vs hidráulica en el periodo seleccionado
Clima vs Generación	Dispersión	Relación entre temperatura media y valor de generación, coloreada por tipo de día

Distribución por tipo día	Boxplot	Distribución estadística del valor de generación según el calendario laboral
---------------------------	---------	--

6.3.3 Panel de KPIs Dinámicos

En la cabecera del dashboard se muestran 7 indicadores que se recalculan en tiempo real con cada cambio de filtro: número de registros, estaciones cubiertas, provincias activas, fuentes de energía, valor medio, temperatura media y precipitación media.

■ **Portabilidad del dashboard:** Al ser un único archivo HTML autocontenido, puede distribuirse por correo electrónico, abrirse directamente en cualquier navegador moderno sin instalación adicional, publicarse en un servidor web estático o incrustarse en un Jupyter Notebook mediante IFrame. No requiere Python, Jupyter ni ninguna dependencia externa en el entorno del usuario final.

6.4 Plan de Monitorización y Mantenimiento

Aspecto	Estrategia
Frecuencia de actualización	Diaria automática vía AWS Lambda (ESIOS). AEMET se actualiza manualmente con periodicidad mensual ejecutando el notebook de la capa Silver.
Detección de model drift	No aplicable en esta fase (sin modelo predictivo). Monitorización de calidad de datos: % de nulos por columna y rango de valores de temperatura y viento.
Estrategia de re-entrenamiento	El pipeline ETL es idempotente: re-ejecutar los notebooks Silver y Gold con datos actualizados genera un nuevo Parquet Gold sin modificar la lógica de transformación.
Control de versiones	Los archivos Parquet en HDFS se sobrescriben con cada ejecución. Para auditoría se conserva el JSON histórico completo en S3 (immutable).
Alertas	No implementadas en esta versión. Como extensión futura: alarma CloudWatch si la Lambda 1 falla o si el JSON diario está vacío.

CONCLUSIONES Síntesis del Proyecto

Logros alcanzados, decisiones técnicas y líneas de trabajo futuro

Logros Técnicos Alcanzados

- Implementación completa de un pipeline ETL en arquitectura Medallion (Bronze / Silver / Gold) sobre Hadoop HDFS.
- Integración exitosa de tres fuentes de datos heterogéneas (API REST, JSON, CSV) en un dataset analítico unificado de ~103.000 registros.
- Automatización de la ingesta diaria de datos de generación eléctrica mediante AWS Lambda y S3, con patrón event-driven.
- Aplicación sistemática de técnicas de calidad de datos: IQR clipping, transformación logarítmica, parsing de formatos mixtos y normalización de fechas.
- Ingeniería de características con alto valor analítico: HDD, CDD, amplitud térmica y precipitación total calculada.
- Generación de un dashboard interactivo HTML autocontenido con 5 tipos de visualización y 7 KPIs dinámicos, distribuible sin dependencias externas.

Decisiones Técnicas Clave

Decisión	Justificación
Inner join como estrategia de integración	Garantiza que cada registro del dataset Gold tenga información completa en las tres dimensiones (clima, energía, calendario). Prioriza calidad sobre volumen.
Parquet como formato de persistencia	Compresión columnar ~60-70% respecto a CSV, soporte de tipos nativos, compatibilidad con el ecosistema Hadoop/Spark y lectura eficiente por columnas.
Clipping IQR vs. eliminación de outliers	El clipping preserva todos los registros estabilizando los extremos, mientras que la eliminación habría reducido aún más un dataset ya acotado temporalmente.
Log10 en variables de viento	La distribución del viento es intrínsecamente log-normal. La transformación mejora la interpretabilidad y prepara la variable para modelos lineales futuros.
Dashboard HTML autocontenido	Elimina la dependencia de un servidor backend, maximiza la portabilidad y permite la distribución inmediata del resultado sin infraestructura adicional.

Líneas de Trabajo Futuro

- **Fase de Modelado (CRISP-DM IV):** Implementar un modelo de regresión que prediga la generación eólica diaria en función de temperatura media, HDD y racha de viento.
- **Ampliación temporal:** Extender el histórico de AEMET y ESIOS a 3–5 años para capturar patrones estacionales completos.
- **Granularidad horaria:** Incorporar datos horarios de ESIOS para análisis intradiario de la curva de demanda.
- **Alertas automáticas:** Implementar alarmas CloudWatch para notificar fallos en la ingesta Lambda o anomalías en la calidad de los datos.
- **Integración con Apache Spark:** Migrar las transformaciones de Pandas a PySpark para escalar el pipeline a volúmenes de datos nacionales completos.

"Los datos son el nuevo petróleo, pero como el petróleo, en bruto son poco útiles. La ingeniería de datos — limpiarlos, transformarlos e integrarlos — es lo que los convierte en valor real." — Clive Humby (adaptado)